RailInsight — Cadrage du projet

Version du 10 octobre 2026

1. Question directrice

> **D'où viennent les retards des TGV : du réseau, des trains ou d'aléas extérieurs ? Et que révèle ce découpage sur les liaisons durablement en difficulté et sur les saisons ?**

Fil rouge : comprendre l'origine des retards. C'est ce que l'application apporte au grand public : choisir *sa* liaison, voir son score de fiabilité, de quoi sont faits ses retards et comment ils évoluent.

Ce qu'on mesure : des causes *déclarées*. Elles sont attribuées par la SNCF, une seule par train (celle de la plus grosse perte de temps). L'étude est descriptive, sans conclusion causale.

2. Décisions validées

Sujet	Décision
Unité d'observation	Une liaison × un mois (pas de donnée train par train)
Agrégation	Jamais de total réseau : un même train compte dans plusieurs liaisons. Vue d'ensemble = distribution des liaisons
Pondération	Toujours par le nombre de trains, jamais de moyenne de taux
Causes	Raisonner en contributions (taux de retard × part de la cause), pas en parts brutes
SNCF Réseau	`prct_cause_infra`, `prct_cause_gestion_trafic`
SNCF Voyageurs	`prct_cause_materiel_roulant`, `prct_cause_gestion_gare`, `prct_cause_prise_en_charge_voyageurs`
Externe	`prct_cause_externe` (inclut les grèves, non isolables)
Saisonnalité	Axe de lecture des causes, pas une catégorie de cause
Classes de comparaison	3 classes de durée de trajet : < 1 h 30 (seuil 5 min), 1 h 30–3 h (10 min), > 3 h (15 min)
Grain du classement	Une valeur par liaison et par an, par classe de durée, petites liaisons exclues
« Durablement en difficulté »	Au-dessus du seuil (quartile supérieur, à confirmer sur la distribution) la majorité des années de la période de référence
Prédiction	Abandonnée : le brief demande de comprendre les causes structurelles
Liaisons internationales	Gardées ou non selon leur part du volume de trains, à mesurer

3. Score de fiabilité (V1)

Élément	Décision
Composantes	Part de trains en retard (seuil de la classe de durée), taux d'annulation, retard moyen de tous les trains (`retard_moyen_tous_trains_arrivee`)
Poids	Égaux : un tiers chacune. A documenter dans la datasheet, avec un test de sensibilité éventuellement
Normalisation	Rang de chaque composante à l'intérieur de la classe de durée
Période	Les 12 derniers mois
Causes	Toutes causes confondues (score « vécu » un retard est un retard) ; la part d'origine interne (Réseau + Voyageurs) est affichée à côté, sans entrer dans le calcul
Historique	Le score n'est pas tracé dans le temps (il est relatif). L'historique montre les 3 composantes en valeurs absolues, année par année

4. Plan d'action par phase

Phase 0 — Préparer les données

- Vérifier le schéma, la période couverte, les doublons, les faux codes (gare « 0 »).
- Contrôler les faux zéros des causes : la somme des six `prct_cause_*` doit valoir environ 100.
- Mesurer la part des liaisons internationales.
- Ouvrir la `DATASHEET.md` (7 sections) et y consigner chaque décision.

Phase 1 — Découper les retards

- Pour chaque liaison : contributions Réseau / Voyageurs / Externe.
- Distribution des liaisons selon leur cause dominante.
- Test de robustesse : reclasser `prise_en_charge_voyageurs` et vérifier que la conclusion tient.

Phase 2 — Les liaisons durablement en difficulté

- Distribution de l'indicateur de retard par classe de durée et par an.
- Choix du seuil et du volume minimal à partir de ces distributions.
- Sélection des liaisons sur une **période de référence**.
- Évolution sur la **période suivante**, à saison égale, et cause qui porte cette évolution.

Phase 3 — Lecture par saison

- Contributions des trois groupes de causes par saisonnalité ou trimestre.

Phase 4 — Score de fiabilité

- Calcul des 3 composantes sur les 12 derniers mois, rang dans la classe de durée, moyenne à poids égaux.
- Test de sensibilité aux poids : si les classements changent fortement, redéfinir les poids.
- Part d'origine interne calculée pour chaque liaison.
- Afficher les 3 composantes en mesure absolues pour nuancer le score de fiabilité.
- Le rang est calculé parmi les liaisons de durée comparable

5. Contenu de l'application

Page	Question	Contenu
Accueil	Pourquoi s'y intéresser ?	Question directrice, chiffres clés, source et licence
D'où viennent les retards ?	Réseau, trains ou aléas ?	Distribution des liaisons par cause dominante
Liaisons en difficulté	Lesquelles, et comment évoluent-elles ?	Classement par classe de durée, tendances, cause qui porte l'évolution
Saisons	Quand les retards apparaissent-ils, et pourquoi ?	Contributions des causes par saison ou trimestre
Ma liaison	Ma liaison est-elle fiable ?	Score de fiabilité + part d'origine interne, historique des 3 composantes, découpage des causes
Données et limites	Peut-on faire confiance aux chiffres ?	Datasheet résumée, interdiction du total réseau, causes déclarées, construction du score

6. Points encore ouverts

- ☐ Seuil exact et volume minimal (après lecture des distributions).
- ☐ Bornes de la période de référence et de la période de suivi.
- ☐ Années atypiques (crise sanitaire, grèves) : gardées, signalées ou exclues.